

Temas avanzadas de Regresión Lineal Múltiple

Análisis de contribución de variables independientes

En el caso de regresión lineal múltiples, algunos variables independientes no están contribuyendo al funcionamiento de la predicción (generación de relación lineal)

Posibles razones

1. Aleatorio -- variables independientes son aleatorio
2. Colinealidad – existen colinealidad con otras variables independientes

Prueba estadística t y valor p

- Para analizar la contribución de cada variable independiente se usa **prueba estadística t** (t de estudiante) y **el valor p**.

Prueba estadística t

Se considera dos grupos X_1, X_2 .

Los promedios de cada grupo son $\bar{X}_1$ y $\bar{X}_2$.

$$t = \frac{X_1 - X_2}{S_{X_1X_2} \sqrt{\frac{2}{n}}}$$

Donde $S_{X_1X_2} = \sqrt{\frac{1}{2}(S_{X_1}^2 + S_{X_2}^2)}$, $S_{X_1}^2$ y $S_{X_2}^2$ son varianzas de dos grupos, y n es número de elementos de cada grupo.

Ejemplo de prueba estadística t (Ejercicio 4)

Escenario: Un profesor desarrolló un método de aprendizaje con el cual los estudiantes aprende mejor. Para mostrar la eficiencia de su método, su grupo de 20 estudiantes se divide aleatoriamente en dos grupos, A y B con 10 estudiantes en cada grupo. Al grupo A, el profesor aplica su método de aprendizaje y al grupo B, aplica el método convencional. Después de un semestre, el departamento de la Universidad aplica un examen a los 20 estudiantes. Los resultados de calificación son siguientes:

grupo	1	2	3	4	5	6	7	8	9	10
A	9.5	8.2	7.1	9.4	9.3	8.4	6.9	8.5	9.8	8.9
B	9.0	7.4	8.2	6.8	7.5	8.9	9.6	6.4	7.1	8.8

Obtener prueba estadística t

Prueba estadística t

$$t = \frac{\bar{X}_1 - \bar{X}_2}{S_{X_1 X_2} \sqrt{\frac{2}{n}}}$$

Donde $S_{X_1 X_2} = \sqrt{\frac{1}{2}(S_{X_1}^2 + S_{X_2}^2)}$,

$S_{X_1}^2$ y $S_{X_2}^2$ son varianzas de dos grupos.

n es numero de elementos de cada grupo.

Prueba estadística t

$$t = \frac{\bar{A} - \bar{B}}{S_{AB} \sqrt{\frac{2}{n}}}$$

$$S_{AB} = \sqrt{\frac{1}{2}(S_A^2 + S_B^2)}$$

S_A^2 y S_B^2 : Varianza de A y B

n: Número de elementos (datos disponibles) en cada grupo.

grupo	1	2	3	4	5	6	7	8	9	10
A	9.5	8.2	7.1	9.4	9.3	8.4	6.9	8.5	9.8	8.9
B	9.0	7.4	8.2	6.8	7.5	8.9	9.6	6.4	7.1	8.8

Respuesta

$$\begin{aligned}\bar{A} &= 8.6, & \bar{B} &= 7.97 \\ S_A &= 0.939, & S_B &= 1.023\end{aligned}$$

Obtenemos S_{AB} con los valores de desviación estándar, obtenemos

$$S_{AB} = \sqrt{\frac{1}{2}(S_A^2 + S_B^2)} \approx 0.982$$

Aplicando la ec. (1), obtenemos el valor de prueba de estadística t.

$$t = \frac{\bar{A} - \bar{B}}{S_{AB}\sqrt{\frac{2}{n}}} = \frac{8.6 - 7.97}{0.982 \times \sqrt{0.2}} = 1.4347 \approx 1.43$$

Análisis de Prueba de estadística t

Prueba estadística t

$$t = \frac{\bar{X}_1 - \bar{X}_2}{S_{X_1 X_2} \sqrt{\frac{2}{n}}}$$

$$S_{X_1 X_2} = \sqrt{\frac{1}{2} (S_{X_1}^2 + S_{X_2}^2)}$$

$S_{X_1}^2$ y $S_{X_2}^2$: Varianza de X_1 y X_2

n : Número de elementos (estudiantes) en cada grupo.

Posibles respuestas

1. Positivo ($t > 0$)
2. Negativo ($t < 0$)
3. Cero ($t = 0$)

¿Qué valor tendrá t en los siguientes tres casos?

- (1) El método de aprendizaje no tenía ningún efecto— promedios de dos grupos A y B son iguales

$$\bar{A} = \bar{B}$$


- (2) El método no funcionó, perjudicó a estudiantes del grupo A.

$$\bar{A} \ll \bar{B}$$

- (3) El método funcionó de maravilla, ya que el promedio del grupo A es muy superior que B.

$$\bar{A} \gg \bar{B}$$


Distribución de t de estudiante



k : El grado de libertad $k=n-1$, n es numero de elementos en cada grupo.

Ejemplo del escenario de método de aprendizaje

$n=10 \rightarrow$ el grado de libertad $k=9$



Valor p y el nivel de significación α


Valor p : un valor que indica si o no hay diferencia **estadística** entre dos grupos. El valor p se compara con el nivel de significación α .

El nivel de significación α : Un valor umbral sobre el valor p. Este nivel depende de área de conocimiento.

Biología y medicina : 0.01 (1%)

Ingeniería : 0.05 (5%)

Ejemplo de valor p



$$\text{P-value} = \int_{|t|}^{\infty} pdf(t \text{ de estudiante})$$

Si el área verde es menor que α , entonces calificación de dos grupos puede decir que tiene una diferencia estadística




El método de aprendizaje funcionó

si el $p > \alpha$ entonces la hipótesis H_0 no se puede rechazar
otro caso la hipótesis H_0 se rechaza

La hipótesis H_0 : No hay evidencia estadística que el método o tratamiento funciona.

Valor p y el nivel de significación



Si el área verde es menor que α , entonces calificación de dos grupos puede decir que tiene una diferencia estadística



El método de aprendizaje funcionó

Pregunta: ¿En este caso, estadísticamente, el método de aprendizaje puede decir que funcionó (diferencio) o no?

Análisis de contribución de variables independientes usando el valor p

- (1) Método de eliminación hacia atrás
- (2) Método de selección hacia adelante
- (3) Método de eliminación bidireccional
- (4) Comparación de scores (puntajes)

Eliminación hacía atrás : Planteamiento

Problema de regresión lineal múltiple

$$y = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

En cada variable independiente de $[x_1, x_2, \dots, x_n]$, se genera una hipótesis nula H_0 :

H_0 (hipótesis nula) para la variable independiente x_i : El modelo sin x_i ofrece mismo funcionamiento que con x_i . --- i-esimo variable independiente x_i no tiene contribución (positivo ni negativo)

H_1 (hipótesis alternativa) : no es H_0

$$y_{con_xi} = \theta_0 x_0 + \theta_1 x_1 + \cdots + \theta_{i-1} x_{i-1} + \theta_i x_i + \theta_{i+1} x_{i+1} + \cdots + \theta_n x_n$$

$$y_{sin_xi} = \tilde{\theta}_0 x_0 + \tilde{\theta}_1 x_1 + \cdots + \tilde{\theta}_{i-1} x_{i-1} + \tilde{\theta}_{i+1} x_{i+1} + \cdots + \tilde{\theta}_n x_n$$

$$\begin{array}{ccc} H_0 & & H_1 \\ Score(y_{con_xi}) \approx Score(y_{sin_xi}) & \text{vs} & Score(y_{con_xi}) > Score(y_{sin_xi}) \end{array}$$

$$y_{con_xi} = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_{i-1} x_{i-1} + \theta_i x_i + \theta_{i+1} x_{i+1} + \dots + \theta_n x_n$$

$$y_{sin_xi} = \tilde{\theta}_0 x_0 + \tilde{\theta}_1 x_1 + \dots + \tilde{\theta}_{i-1} x_{i-1} + \tilde{\theta}_{i+1} x_{i+1} + \dots + \tilde{\theta}_n x_n$$

Grupo-A : incluir todos los variables independientes $x_0, x_1, x_2, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n$

Grupo-B : incluir todos los variables independientes excepto variable x_i ,

$$x_0, x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n$$

Hipótesis H0 : $Score(y_{con_xi}) \approx Score(y_{sin_xi}) \rightarrow$ Grupo A y Grupo B no hay diferencia (estadísticamente)

--- la variable independiente x_i no está contribuyendo para la estimación de variable dependiente

Hipótesis H1 : $Score(y_{con_xi}) > Score(y_{sin_xi}) \rightarrow$ Grupo A y Grupo B presenta una diferencia (estadísticamente)

--- la variable independiente x_i es importante para la estimación

Para rechazar o no rechazar hipótesis H_0 , se usa la prueba estadística t de estudiante.

Prueba estadística t

$$t = \frac{\bar{A} - \bar{B}}{S_{AB} \sqrt{\frac{2}{n}}}$$

$$S_{AB} = \sqrt{\frac{1}{2} (S_A^2 + S_B^2)}$$

S_A^2 y S_B^2 : Varianza de A y B

n : Número de elementos (datos disponibles) en cada grupo.

Eliminación hacía atrás


- 1) Definir el valor de factor de significación α ($\alpha=0.05$).
- 2) Se calcula el modelo con todas las variables independientes en este momento
- 3) Obtener los valores-p de cada una de las variables independientes excluida
- 4) Seleccionar una variable con el máximo valor-p, y comparar el valor-p máximo con el factor de significación α . ($\alpha=0.05$, o sea 5%)

if $\max(p_1, p_2, p_3, \dots, p_n) > \alpha$ entonces

$x_{\arg(\max(p_1, p_2, p_3, \dots, p_n))}$ es eliminado y repetir los procesos (2)-(4).

otro caso: terminar ajuste.

El valor t de estudiante



$$P\text{-value} = \int_{|t|}^{\infty} pdf(t \text{ of student})$$

El valor t significa el grado de importancia del variable Independiente.

Pregunta 1

Si el valor t de un variable independiente x1 excluida es 2.8 y el valor t de variable independiente excluida x2 es 1.8.

¿Cuál de las dos variables independientes es más importante en el modelo de regresión lineal múltiple?


Preguntas 2

Si el valor t de un variable independiente x1 excluida es 2.8 y el valor t de variable independiente x2 excluida es -2.8.

¿Cuál de las dos variables independientes es más importante en el modelo de regresión lineal múltiple?

El valor p (p-value)

$$P\text{-value} = \int_{|t|}^{\infty} pdf(t - student)$$



El valor p indica el grado de significación de cada variable independiente.

Pregunta 1

¿existe el valor p negativo?

Pregunta 2

El valor p de la variable independiente x1 excluida es 0.01, mientras el valor p de la variable independiente x2 excluida es 0.07.

¿Cuál es las dos variables independiente es más importante?

Pruebas estadísticas

Uso muy común de pruebas estadísticas

-- Análisis de la eficacia de un fármaco o un tratamiento nuevo

(1) La población se divide en dos grupos: uno tratado con el nuevo fármaco y otro que recibe un placebo.

(2) Después de cierto tiempo, analiza resultados de ambos grupos en la forma numérica.

(3) Analizar diferencia de resultado usando prueba estadística

Pruebas estadísticas además de t de estudiante

- Chi-cuadrado --- uso de datos categóricos
- ANOVA --- más de tres grupos

Implementación

Para analizar estadísticamente el modelo de regresión lineal, hay que usar otra librería de Python llamado “statsmodels” en lugar de “sklearn”.

La librería “statsmodels” contiene varios modelos de predicción:

- **OLS : Ordinary Least Square**
- WLS: Weighted Least Square
- GLS: Generalized Least Square

La librería “statsmodels” proporciona el valor de t, el valor p y el score (R^2).

`conda install anaconda::statsmodels`

Práctica-1

Objetivo: Predecir la calidad de vino tinto (variable dependiente) usando varios factores o aspectos de cada vino (variables independientes).

Metodología: uso de librería *statsmodels.api* para analizar contribución de cada variables independientes.

El número total de datos: 1599 → el grado de libertad es 1598

El número de variables independientes: 11 (ácidos, PH, azúcar residual, etc.) + constante (1)

La variable dependiente: Calidad

(0-10, pero la base de datos tiene 3 -8)

Data set

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
0	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5
1	7.8	0.88	0.00	2.6	0.098	25.0	67.0	0.9968	3.20	0.68	9.8	5
2	7.8	0.76	0.04	2.3	0.092	15.0	54.0	0.9970	3.26	0.65	9.8	5
3	11.2	0.28	0.56	1.9	0.075	17.0	60.0	0.9980	3.16	0.58	9.8	6
4	7.4	0.70	0.00	1.9	0.076	11.0	34.0	0.9978	3.51	0.56	9.4	5

Los datos proporcionados por el sistema (parte 1)

OLS Regression Results

```
=====
Dep. Variable:          quality          R-squared:          0.361
Model:                  OLS              Adj. R-squared:     0.356
Method:                 Least Squares    F-statistic:        81.35
Date:                   Sat, 31 Oct 2020  Prob (F-statistic):  1.79e-145
Time:                   18:52:17          Log-Likelihood:     -1569.1
No. Observations:       1599             AIC:                3162.
Df Residuals:           1587             BIC:                3227.
Df Model:               11
Covariance Type:        nonrobust
=====
```


R-squared (R-cuadrado), R-cuadrado ajustado, F-statistics, AIC y BIC

R^2 (R-cuadrado) se calcula como:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

$$SS_{tot} = \sum (y_i - \bar{y})^2$$

$$SS_{res} = \sum (y_i - f_i)^2 = \sum e^2$$

- Cuando el modelo predice perfectamente el valor de R^2 es 1, ya que error es 0.
- Cuando el modelo predice el nivel de su promedio (base-line), el valor de R^2 es 0.
- Cuando el modelo predice peor que el nivel de base-line, el valor de R^2 es negativo.

R^2 ajustado : El valor de R-cuadrado evitando overfitting

F-statistics: un valor que indica significación de diferencia entre promedio de dos grupos


AIC: Akaike Information Criterion

BIC: Bayesian Informatio Criterion

Los datos proporcionados por el sistema (parte 2)

Variables independientes	coef (θ)	std err	t	P> t	[0.025	0.975]
const (=1)	5.7126	0.151	37.846	0.000	5.416	6.009
fixed acidity	0.2824	0.293	0.963	0.336	-0.293	0.858
volatile acidity	-1.5820	0.177	-8.948	0.000	-1.929	-1.235
citric acid	-0.1826	0.147	-1.240	0.215	-0.471	0.106
residual sugar	0.2384	0.219	1.089	0.276	-0.191	0.668
chlorides	-1.1227	0.251	-4.470	0.000	-1.615	-0.630
free sulfur dioxide	0.3097	0.154	2.009	0.045	0.007	0.612
total sulfur dioxide	-0.9239	0.206	-4.480	0.000	-1.328	-0.519
density	-0.2435	0.295	-0.827	0.409	-0.821	0.334
pH	-0.5253	0.243	-2.159	0.031	-1.003	-0.048
sulphates	1.5303	0.191	8.014	0.000	1.156	1.905
alcohol	1.7953	0.172	10.429	0.000	1.458	2.133

Distribución de t de estudiante



Análisis de resultados


Variables independientes	coef (θ)	std err	t	P> t	[0.025	0.975]
const (=1)	5.7126	0.151	37.846	0.000	5.416	6.009
fixed acidity	0.2824	0.293	0.963	0.336	-0.293	0.858
volatile acidity	-1.5820	0.177	-8.948	0.000	-1.929	-1.235
citric acid	-0.1826	0.147	-1.240	0.215	-0.471	0.106

$$t = \frac{X_1 - X_2}{S_{X_1 X_2} \sqrt{\frac{2}{n}}}$$

X_1 : Modelo con variable independiente "citric acid"
 X_2 : Modelo sin variable independiente "citric acid"


n: numero de datos (generalmente muy grande) =1599
k: el grado de libertad $k=n-1 =1598 \rightarrow$ infinit

$$S_{X_1 X_2} = \sqrt{\frac{1}{2} (S_{X_1}^2 + S_{X_2}^2)}$$



Análisis de resultados

Variables independientes	coef (θ)	std err	t	P> t	[0.025	0.975]
const (=1)	5.7126	0.151	37.846	0.000	5.416	6.009
fixed acidity	0.2824	0.293	0.963	0.336	-0.293	0.858
volatile acidity	-1.5820	0.177	-8.948	0.000	-1.929	-1.235
citric acid	-0.1826	0.147	-1.240	0.215	-0.471	0.106



Grado de libertad (df) = 1598


```
from scipy.stats import t
import numpy as np
import matplotlib.pyplot as plt

df=1598
x= np.linspace(start=-10.0, stop=10.0, num=1000)
pdf_value = t.pdf(x,df)

plt.plot(x,pdf_value)
plt.title("Función de densidad de probabilidad")
plt.xlabel("valor t")
plt.ylabel("PDF")
plt.show()
```

Análisis de resultados

Variables independientes	coef (θ)	std err	t	P> t	[0.025	0.975]
const (=1)	5.7126	0.151	37.846	0.000	5.416	6.009
fixed acidity	0.2824	0.293	0.963	0.336	-0.293	0.858
volatile acidity	-1.5820	0.177	-8.948	0.000	-1.929	-1.235
citric acid	-0.1826	0.147	-1.240	0.215	-0.471	0.106



El valor de $|t|$ (el valor absoluto de t) pequeño (cerca de cero)



$$Score(y_{con_xi}) \approx Score(y_{sin_xi})$$



El valor de p (p-value) es grande

El valor $p >$ factor de significación $\rightarrow$ estadísticamente

$$Score(y_{con_xi}) \approx Score(y_{sin_xi})$$



Variable independiente x_i se puede eliminar

Los datos proporcionados por el sistema (parte 2)

Variables independientes	coef (θ)	std err	t	P> t	[0.025	0.975]
const (=1)	5.7126	0.151	37.846	0.000	5.416	6.009
fixed acidity	0.2824	0.293	0.963	0.336	-0.293	0.858
volatile acidity	-1.5820	0.177	-8.948	0.000	-1.929	-1.235
citric acid	-0.1826	0.147	-1.240	0.215	-0.471	0.106
residual sugar	0.2384	0.219	1.089	0.276	-0.191	0.668
chlorides	-1.1227	0.251	-4.470	0.000	-1.615	-0.630
free sulfur dioxide	0.3097	0.154	2.009	0.045	0.007	0.612
total sulfur dioxide	-0.9239	0.206	-4.480	0.000	-1.328	-0.519
density	-0.2435	0.295	-0.827	0.409	-0.821	0.334
pH	-0.5253	0.243	-2.159	0.031	-1.003	-0.048
sulphates	1.5303	0.191	8.014	0.000	1.156	1.905
alcohol	1.7953	0.172	10.429	0.000	1.458	2.133

Pregunta: Considerando que el factor de significación α es 0.05, cuál de los variables independientes debe eliminarse?

Práctica-2

Objetivo: Aplicar el método de eliminación hacia atrás manualmente.

Paso-1: Eliminar el variable independiente “density “, ya que tiene mayor valor p y el cual es mayor que $\alpha=0.05$.

R-squared: 0.360

Adj. R-squared: 0.356

	coef	std err	t	P> t	[0.025	0.975]
const	5.7015	0.150	37.925	0.000	5.407	5.996
fixed acidity	0.0920	0.181	0.507	0.612	-0.264	0.448
volatile acidity	-1.6008	0.175	-9.130	0.000	-1.945	-1.257
citric acid	-0.1836	0.147	-1.248	0.212	-0.472	0.105
residual sugar	0.1307	0.176	0.743	0.458	-0.215	0.476
chlorides	-1.1421	0.250	-4.568	0.000	-1.633	-0.652
free sulfur dioxide	0.3205	0.154	2.087	0.037	0.019	0.622
total sulfur dioxide	-0.9373	0.206	-4.560	0.000	-1.341	-0.534
pH	-0.6404	0.200	-3.210	0.001	-1.032	-0.249
sulphates	1.4911	0.185	8.062	0.000	1.128	1.854
alcohol	1.9028	0.113	16.883	0.000	1.682	2.124

Paso-2: Eliminar el variable independiente “fixed acidity”, ya que tiene un mayor valor p.

R-squared: 0.360

Adj. R-squared: 0.357

	coef	std err	t	P> t	[0.025	0.975]
const	5.7460	0.122	47.065	0.000	5.507	5.985
volatile acidity	-1.5790	0.170	-9.292	0.000	-1.912	-1.246
citric acid	-0.1426	0.123	-1.160	0.246	-0.384	0.099
residual sugar	0.1372	0.175	0.782	0.434	-0.207	0.481
chlorides	-1.1750	0.241	-4.867	0.000	-1.649	-0.701
free sulfur dioxide	0.3260	0.153	2.128	0.033	0.026	0.626
total sulfur dioxide	-0.9660	0.198	-4.889	0.000	-1.354	-0.578
pH	-0.6941	0.169	-4.103	0.000	-1.026	-0.362
sulphates	1.4978	0.184	8.121	0.000	1.136	1.860
alcohol	1.8957	0.112	16.955	0.000	1.676	2.115

Paso-3: Eliminar el variable independiente “residual sugar”.

Paso-4: Después del paso 3, eliminar “citric acid”

R-squared: 0.359

Adj. R-squared: 0.357

	coef	std err	t	P> t	[0.025	0.975]
const	5.6675	0.094	60.274	0.000	5.483	5.852
volatile acidity	-1.4786	0.147	-10.043	0.000	-1.767	-1.190
chlorides	-1.2087	0.238	-5.076	0.000	-1.676	-0.742
free sulfur dioxide	0.3605	0.151	2.389	0.017	0.064	0.657
total sulfur dioxide	-0.9855	0.194	-5.070	0.000	-1.367	-0.604
pH	-0.6130	0.149	-4.106	0.000	-0.906	-0.320
sulphates	1.4741	0.184	8.031	0.000	1.114	1.834
alcohol	1.8805	0.109	17.225	0.000	1.666	2.095

Ningún variables independientes tiene valor p mayor que α (0.05)

Las variables independientes que quedan son variables significativos para estimar la calidad de vino.

Práctica-3

Objetivo: Automatizar el proceso de eliminación hacia atrás.

```
regressor_OLS = sm.OLS(y, X).fit() # Obtener el modelo regressor_OLS con los datos actuales
print(regressor_OLS.summary())
maxVar = max(regressor_OLS.pvalues) # obtener máximo p-value

if maxVar > sl:
    for j in range(0, numVars - i):
        if (regressor_OLS.pvalues[j] == maxVar):
            X = X.drop(features[j-1],axis=1)
            features.remove(features[j-1])
```

Tarea: Regresión lineal múltiple-temas avanzados

1. Aplicar OLS de librería *statsmodels.api* a la base de datos '50_Startups.csv'
2. Analizar p-value de cada variable independiente
3. Aplicar el algoritmo de “Eliminación hacia atrás”
4. Analizar el resultado desde el punto de vista R-cuadrado y R-cuadrado ajustado.