



Máquina de Soporte Vectorial (SVM)


Teoría




Concepto básico: Linealmente separable e inseparable





Linealmente separable







Linealmente inseparables



Linealmente Separabile






Objetivo de SVM


Seleccionar una línea (plano o hiperplano) de separación que maximiza el margen.

2D



Separación: Línea 1D

3D




Separación: Plano 2D

N dimensión > 3D

**Separación: Hiperplano
del orden N-1**

Ecuación de una línea: $w^T x + b = 0$



Línea roja:

$$x_2 = 0.5x_1 + 2 \rightarrow 0.5x_1 - x_2 + 2 = 0$$

$$w = \begin{bmatrix} 0.5 \\ -1 \end{bmatrix}, x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, b = 2$$

Pregunta 1: Representar línea azul y línea verde con matriz W de 2×1 y un escalar b .

Respuesta-1


Línea-azul $x_2 = -x_1 + 5$

$$x_1 + x_2 - 5 = 0 \quad \mathbf{w} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, b = -5$$

Línea-verde $x_2 = 2x_1 - 6$

$$2x_1 - x_2 - 6 = 0 \quad \mathbf{w} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, b = -6$$


Formula de plano e hiperplano



$$w^T x + b = 0$$

$$w = \begin{bmatrix} \alpha \\ \beta \\ \gamma \end{bmatrix}, x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, b = 0$$

Clasificación



$$K_1: \mathbf{w}^T \mathbf{x}_i + b < 0 \quad \rightarrow \mathbf{x}_i \in K_1$$

$$K_2: \mathbf{w}^T \mathbf{x}_i + b > 0 \quad \rightarrow \mathbf{x}_i \in K_2$$

Línea azul $\mathbf{x}_2 = \mathbf{x}_1 + 0 \rightarrow \mathbf{w} = [-1, 1], b = 0$

$$K_1: \begin{bmatrix} -1 \\ 1 \end{bmatrix} [x_1 \ x_2] + 0 < 0 \quad \rightarrow \mathbf{x}_i \in K_1$$

$$K_2: \begin{bmatrix} -1 \\ 1 \end{bmatrix} [x_1 \ x_2] + 0 > 0 \quad \rightarrow \mathbf{x}_i \in K_2$$


Línea morada $-3x_1 + 7x_2 - 14 = 0$

$$K_1: \begin{bmatrix} -3 \\ 7 \end{bmatrix} [x_1 \ x_2] - 14 < 0 \quad \rightarrow \mathbf{x}_i \in K_1$$

$$K_2: \begin{bmatrix} -3 \\ 7 \end{bmatrix} [x_1 \ x_2] - 14 > 0 \quad \rightarrow \mathbf{x}_i \in K_2$$

Ejemplo

Clasificación



$$K_1: w^T x_i + b < 0 \quad \rightarrow x_i \in K_1$$


$$K_2: w^T x_i + b > 0 \quad \rightarrow x_i \in K_2$$



$$t_i (w^T x_i + b) > 0,$$


$$t_i = \begin{cases} -1 & x_i \in K_1 \\ 1 & x_i \in K_2 \end{cases}$$

Obtener Margen



d : Distancia entre el vector de soporte y línea de separación

Distancia entre un punto y una línea



$$\mathbf{w}^T \mathbf{x} + b = 0$$

$$d = \frac{|w_1 x_1 + w_2 x_2 + b|}{\sqrt{w_1^2 + w_2^2}}$$

$$\mathbf{w} = [w_1 \quad w_2]^T \text{ y } \mathbf{x} = [x_1 \quad x_2]^T$$

Pregunta-2: Obtener distancia entre el punto y la línea

- (1) El punto $(0,0)$ y la línea $3x-4y+4=0$
- (2) El punto $(-2,3)$ y la línea $y=-2x+4$

Respuesta-2

$$d = \frac{|w_1x_1 + w_2x_2 + b|}{\sqrt{w_1^2 + w_2^2}}$$

(1) El punto (0,0) y la línea $3x-4y+4=0$


$$d = \frac{4}{\sqrt{9+16}} = \frac{4}{5} = 0.8$$

(2) El punto (-2,3) y la línea $y=-2x+4$

$$2x + y - 4 = 0$$

$$d = \frac{|2 \times (-2) + 3 - 4|}{\sqrt{4+1}} = \frac{5}{\sqrt{5}} = \sqrt{5}$$

Generalización del problema (Hiperplano)



d : Distancia entre el vector de soporte y la línea de separación

$$d = \frac{|w_1 x_1 + w_2 x_2 + \dots + w_p x_p + b|}{\sqrt{w_1^2 + w_2^2 + \dots + w_p^2}} = \frac{|w^T x + b|}{\|w\|}$$

M : distancia entre línea de separación y el vector de soporte



$$\max_{w,b} M, \text{ bajo la condición de } \frac{t_i(w^T x_i + b)}{\|w\|} \geq M$$

$$\text{Para los vectores de soporte: } \frac{t_i(w^T x_i + b)}{\|w\|} = M$$

$$t_i = \begin{cases} -1 & x_i \in K_1 \\ 1 & x_i \in K_2 \end{cases}$$

Problema de optimización y manipulación matemática

objetivo

$$\max_{\mathbf{w}, b} M, \quad \text{bajo la condición de } \frac{t_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|} \geq M$$

Esta condición se dividen por M, ya que M es el margen, el cual es siempre positivo.

$$\frac{t_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|} \geq M \quad (1)$$

$$\frac{t_i(\mathbf{w}^T \mathbf{x}_i + b)}{M \|\mathbf{w}\|} \geq 1 \quad (2)$$

Introduciendo dos variables: $\tilde{\mathbf{w}} = \frac{\mathbf{w}}{M \|\mathbf{w}\|}$ y $\tilde{b} = \frac{b}{M \|\mathbf{w}\|}$, y reemplazando por estas variables, obtenemos

$$t_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b}) \geq 1 \quad (3)$$

$$\text{También, de } \tilde{\mathbf{w}} = \frac{\mathbf{w}}{M \|\mathbf{w}\|}, \text{ obtenemos } \frac{1}{\|\tilde{\mathbf{w}}\|} = \frac{M \|\mathbf{w}\|}{\|\mathbf{w}\|} = M \quad (4)$$

objetivo

$$\max_{w,b} M, \quad \text{bajo la condición de } \frac{t_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|} \geq M \quad \xrightarrow{\quad} \quad t_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b}) \geq 1$$

Varios reemplazos

$$\text{de } \tilde{\mathbf{w}} = \frac{\mathbf{w}}{M\|\mathbf{w}\|}, \text{ obtenemos } \frac{1}{\|\tilde{\mathbf{w}}\|} = \frac{M\|\mathbf{w}\|}{\|\mathbf{w}\|} = M$$

$$\max_{\tilde{\mathbf{w}}, \tilde{b}} \frac{1}{\|\tilde{\mathbf{w}}\|}, \quad \text{bajo la condición de } t_i(\tilde{\mathbf{w}}^T \mathbf{x}_i + \tilde{b}) \geq 1$$

Simplificación


$$\min_{\bar{\mathbf{w}}, \tilde{b}} \frac{1}{2} \|\bar{\mathbf{w}}\|^2, \quad \text{bajo la condición de } t_i(\bar{\mathbf{w}}^T \mathbf{x}_i + \tilde{b}) \geq 1$$

$$\bar{\mathbf{w}} = \frac{1}{\|\tilde{\mathbf{w}}\|} \quad \bar{\mathbf{w}} \rightarrow \mathbf{w} \quad \tilde{b} \rightarrow b$$

Nota: ½ fue agregado para simplificación en el proceso de optimización

Margen rígido y margen suave (Hard Margin & Soft Margin)

La condición debe aflojar un poco.



$$t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad (\text{margen rígido})$$



$$t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \quad (\text{margen suave})$$

$$\xi_i = \max \left\{ 0, M - \frac{t_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|} \right\} \quad \text{Variable Stack}$$

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \right\}, \quad \text{bajo la condición de } t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

Margen rígido y margen suave

Margen	Problema	Optimización	Condición
Margen rígido	Linealmente separable	$\min_{\mathbf{w}, b} \frac{1}{2} \ \mathbf{w}\ ^2$	$t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ $i = 1, 2, \dots, n$
Margen suave	Linealmente inseparable	$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \ \mathbf{w}\ ^2 + C \sum_{i=1}^n \xi_i \right\}$	$t_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$ $\xi_i \geq 0, i = 1, 2, \dots, n$

El problema de margen es problema de optimización con condiciones

Método de los multiplicadores de Lagrange

El método de los multiplicadores de Lagrange es un método que usa frecuentemente para resolver el problema de optimización con condición.

Obtener un punto mínimo de función de objetivo $f(x)$ bajo n condiciones basadas en desigualdad $g_j(x) \leq 0, j = 1, \dots, n$

Paso 1: Generar una función de Lagrange $\mathcal{L}(x, \alpha)$, la cual es una combinación lineal con la función de objetivo y desigualdades pesados

$$\mathcal{L}(x, \alpha) = f(x) + \sum_{i=1}^n \alpha_i g_i(x)$$

Donde **x es variable primaria** y **α es variable dual** con Lagrange multiplicadores α_i

Método de los multiplicadores de Lagrange

Paso 2: Obtener solución óptimo (x, α) usando método de Lagrange con siguiente 4 condiciones:

x : variable principal
 α : variable dual

$$\mathcal{L}(x, \alpha) = f(x) + \sum_{i=1}^n \alpha_i g_i(x)$$

(1) Derivada parcial de la función de Lagrange con respecto a variable principal x es 0.

$$\frac{\partial \mathcal{L}(x, \alpha)}{\partial x} = \frac{\partial f(x)}{\partial x} + \sum_{i=1}^n \alpha_i \frac{\partial g_i(x)}{\partial x} = 0$$

(2) Derivada parcial de la función de Lagrange con respecto a variable dual α tiene que ser menor o igual a 0.

$$\frac{\partial \mathcal{L}(x, \alpha)}{\partial \alpha_i} = g_i(x) \leq 0$$

(3) Todas las variables duales son mayores o igual a 0

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, n$$



(4) Todos términos $\alpha_i g_i(x)$ es igual a 0.

$$\alpha_i g_i(x) = 0, i = 1, 2, \dots, n$$

Ejemplo del uso de método de los multiplicadores de Lagrange

$$\mathcal{L}((x, y), \alpha) = f(x, y) + \sum_{i=1}^n \alpha_i g_i(x, y) = f(x, y) + \alpha g(x, y)$$

Obtener el valor mínimo de la función de objetivo $f(x, y) = (x - 2)^2 + (y - 1)^2$ bajo la restricción de $g(x, y) = x + y - 2 \leq 0$.



Solución:

$$\mathcal{L}(x, y, \alpha) = f(x, y) + \sum_{i=1}^n \alpha_i g_i(x, y) = f(x, y) + \alpha g(x, y)$$

$$f(x, y) = (x - 2)^2 + (y - 1)^2 \quad g(x, y) = x + y - 2 \leq 0.$$

La función de Lagrange

$$\mathcal{L}(x, y, \alpha) = (x - 2)^2 + (y - 1)^2 + \alpha(x + y - 2) = x^2 - 4x + y^2 - 2y + 5 + \alpha(x + y - 2)$$

(x,y): variables principales
 α : variable dual

Derivada parcial de la función de Lagrange con respecto a variables principales x y y es 0.

$$\frac{\partial \mathcal{L}(x, y, \alpha)}{\partial x} = 2x - 4 + \alpha = 0 \quad (1)$$

$$\frac{\partial \mathcal{L}(x, y, \alpha)}{\partial y} = 2y - 2 + \alpha = 0 \quad (2)$$

Derivada parcial de la función de Lagrange con respecto a variable dual α tiene que ser menor o igual a 0.

Pregunta 3: Obtener los valores de x y y

$$\frac{\partial \mathcal{L}(x, \alpha)}{\partial \alpha} = x + y - 2 \leq 0 \quad (3)$$

Todas las variables duales son mayores o igual a 0

$$\alpha \geq 0 \quad (4)$$

Todos términos $\alpha_i g_i(x)$ es igual a 0.

$$\alpha(x + y - 2) = 0 \quad (5)$$

Respuesta-3

De la ec. (5), $\alpha(x + y - 2) = 0$, obtenemos

$$\alpha = 0 \quad o \quad x + y - 2 = 0$$

Opción-1: $\alpha = 0$. De las ecs. (1) y (2), obtenemos $x=2$ y $y=1$

Esta solución no cumple la condición dada por (3).

Por lo tanto esta opción está rechazada.

Opción-2: $x + y - 2 = 0$ (5)

De las ecs. (1) y (2), eliminando α , obtenemos

$$x - y - 1 = 0 \quad (6)$$

Resolviendo las ecuaciones simultaneas (5) y (6),
obtenemos:

$$x = \frac{3}{2}=1.5, \quad y = \frac{1}{2}=0.5$$

Obtener un punto mínimo de función de objetivo $f(x)$
bajo n condiciones basadas en desigualdad $g_j(x) \leq 0, j = 1, \dots, n$

Obtención de W y b de SVM usando el método de Lagrange

Margen suave	Linealmente inseparable	$\min_{w,b} \left\{ \frac{1}{2} \ w\ ^2 + C \sum_{i=1}^n \xi_i \right\}$	$t_i(w^T x_i + b) \geq 1 - \xi_i$ $\xi_i \geq 0, i = 1, 2, \dots, n$
--------------	-------------------------	--	---

Función de objetivo

$$f(w, \xi) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Las condiciones:

$$t_i(w^T x_i + b) \geq 1 - \xi_i \text{ y } \xi_i \geq 0$$

Para poder aplicar el método de los multiplicadores de Lagrange, las condiciones tenemos que modificar de acuerdo al método.

$$1 - \xi_i - t_i(w^T x_i + b) \leq 0 \quad (\text{condición-1})$$

$$-\xi_i \leq 0 \quad (\text{condición-2})$$

Combinando función de objetivo y las condiciones (restricciones), la función de Lagrange se puede expresar como:

$$f(\mathbf{w}, \xi) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

$$1 - \xi_i - t_i(\mathbf{w}^T \mathbf{x}_i + b) \leq 0 \quad (\text{condición-1})$$

$$-\xi_i \leq 0 \quad (\text{condición-2})$$

Paso 1: Generar una función de Lagrange $\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta)$, la cual es una combinación lineal con la función de objetivo y desigualdades pesados

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i \{t_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i\} - \sum_{i=1}^n \beta_i \xi_i$$

$\mathbf{w}, b, \xi$: Variables principales
 α, β : Variables Duales

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i \{t_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i\} - \sum_{i=1}^n \beta_i \xi_i$$

Paso 2: Obtener solución óptimo ($\mathbf{x}, \alpha$) usando método de Lagrange con las 4 condiciones:

Condición-1(1) --- derivada de función Lagrange con variable principal w es cero

$$\begin{aligned} \frac{\partial \mathcal{L}(w, b, \xi, \alpha, \beta)}{\partial w} &= \frac{\partial f(w, b, \xi)}{\partial w} + \sum_{i=1}^n \alpha_i \frac{\partial g_i(w, b, \xi_i)}{\partial w} + \frac{\partial}{\partial w} \sum_{i=1}^n \beta_i \xi_i = 0 \\ &= w - \sum_{i=1}^N \alpha_i t_i x_i = 0 \end{aligned}$$

Condición-1(2) ---- derivada de función de Lagrange con variable principal b es cero

$$\begin{aligned} \frac{\partial \mathcal{L}(w, b, \xi, \alpha, \beta)}{\partial b} &= \frac{\partial f(w, b, \xi)}{\partial b} + \sum_{i=1}^n \alpha_i \frac{\partial g_i(w, b, \xi_i)}{\partial b} + \frac{\partial}{\partial b} \sum_{i=1}^n \beta_i \xi_i = 0 \\ &= - \sum_{i=1}^n \alpha_i t_i = 0 \end{aligned}$$

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i \{t_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i\} - \sum_{i=1}^n \beta_i \xi_i$$

Condición-1 --- derivada de función Lagrange con variable principal ξ es cero

$$\begin{aligned} \frac{\partial \mathcal{L}(w, b, \xi, \alpha, \beta)}{\partial \xi} &= \frac{\partial f(w, b, \xi)}{\partial \xi} + \sum_{i=1}^n \alpha_i \frac{\partial g_i(w, b, \xi_i)}{\partial \xi} + \frac{\partial}{\partial b} \sum_{i=1}^n \beta_i \xi_i = 0 \\ &= C - \alpha_i - \beta_i = 0 \end{aligned}$$

De la condición 1, obtenemos:

$$w = \sum_{i=1}^N \alpha_i t_i x_i$$

$$\sum_{i=1}^n \alpha_i t_i = 0$$

$$\alpha_i + \beta_i = C$$

(2) Derivada parcial de la función de Lagrange con respecto a variables duales α y β tiene que ser menor o igual a 0.

$$\{t_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i\} \leq 0 \quad \text{para } i=1..n$$

$$\xi_i \leq 0, \quad \text{para } i = 1 \dots n$$

(3) Todas las variables duales son mayores o igual a 0

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, n$$

$$\beta_i \geq 0, \quad i = 1, 2, \dots, n$$

(4) Todos términos $\alpha_i g_i(x)$ es igual a 0.

$$\alpha_i \{1 - \xi_i - t_i(\mathbf{w}^T \mathbf{x}_i + b)\} = 0, \quad i = 1, 2, \dots, n$$

$$-\beta_i \xi_i = 0, \quad i = 1, 2, \dots, n$$

Aplicando 4 condiciones del método de Lagrange, obtiene $\mathbf{w}$ y b

Finalmente, la función de Lagrange $\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta)$ se puede simplificar como:



$$\tilde{\mathcal{L}}(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_i^n \sum_j^n \alpha_i \alpha_j t_i t_j x_i^T x_j$$

Obtener α que maximiza $\tilde{\mathcal{L}}(\alpha)$


En Sklearn, se aplica un algoritmo óptimo para resolver este problema eficientemente

Datos linealmente no separables

Proyección a alta dimensión: Planteamiento de problema




Proyección a alta dimensión



Teóricamente, un patrón de n -dimensión se puede separar linealmente con hiper-plano de $n-1$ dimensión

Proyección a alta dimensión



$X = [x_1, x_2]$ Dimensión 2



$\phi(X) = (x_1^2, x_2^2, x_1x_2, x_1, x_2)$ Dimensión 5

Linealmente separable

$x_1^2 + x_2^2 \leq 1$ -- -- *clase de azul*

$x_1^2 + x_2^2 \geq 1$ -- -- *clase de naranja*

Kernel Trick (Trampa de kernel)

La trampa de Kernel es una técnica para resolver el problema de alta complejidad. El uso de algún kernel específico evita el cálculo de mapeo $\phi(x)$, reduciendo drásticamente la complejidad computacional.


Función de Kernel mas usado

(1) *kernel Gaussianao* : $K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$

(2) *kernel Polynomial* : $K(x_i, x_j) = (x_i^T x_j + C)^d$

(3) *kernel Sigmoidal* : $K(x_i, x_j) = \tanh(b x_i^T x_j + C)$

Expansión del SVM para múltiples clases




Uno contra uno


Línea negra

Línea azul

Línea naranja



Zoom




No es amarilla, ni negra ni azul

**Region que no
clasifica**

Expansión del SVM para múltiples clases

One-vs-all (one-vs-rest)



Implementación en Sklearn

```
from sklearn.svm import LinearSVC  
from sklearn.svm import SVC
```

```
class sklearn.svm.LinearSVC(  
X, # Patron de entrenamiento  
Y, # Etiqueta  
penalty='l2',  
loss='squared_hinge', # función "hinge" es opcional  
dual=True, # Seleccionar algoritmo de optimización  
tol=0.0001,  
C=1.0, # Cuando usa margen suave  
multi_class='ovr', # 'ovr' significa uno vs. resto → 'crammer_singer'  
fit_intercept=True,  
intercept_scaling=1,  
class_weight=None,  
verbose=0,  
random_state=None,  
max_iter=1000)
```

$$\min_{\mathbf{w}, b} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \right\}$$

Función de pérdida Hinge (Hinge Loss Function)

$$l(y) = \max(0, 1 - ty)$$


donde

$$t_i = \begin{cases} -1 & x_i \in K_1 \\ 1 & x_i \in K_2 \end{cases}$$

$$\mathbf{y} = \mathbf{w}^T \mathbf{x} + b$$


Cuando la clasificación es correcta, los signos de $\mathbf{y}$ y $\mathbf{t}$ son las mismas. En este caso, t^*y es positivo.

En otro caso, t^*y es negativo, y el valor de la función de es $1 - t^*y$. Por ejemplo, $t^*y = -2$, $l(y) = 3$





```
class sklearn.svm.SVC(  
X, # Patron de entrenamiento  
Y, # Datos deseados (Target)  
C=1.0,  
kernel='rbf', #{'linear', 'poly', 'rbf', 'sigmoid', 'precomputed'} 'rbf' → Radial Basis Function  
degree=3, # Solo kernel polinomio  
gamma='scale',  
coef0=0.0,  
shrinking=True,  
probability=False,  
tol=0.001,  
cache_size=200,  
class_weight=None, v  
erbose=False,  
max_iter=1,  
decision_function_shape='ovr',  
break_ties=False,  
random_state=None  
)
```




Ejemplo-1: Base de datos Iris




Ejemplo-1: Base de datos Iris





Clasificación lineal (SVC(kernel = "lineal") o LinearSVC)





Accuracy=100%




Clasificación lineal SVC(kernel = "rbf")




Clasificación lineal SVC(kernel = "sigmoid")



Clasificación lineal SVC(kernel = "poly", coef0=1.5)




Accuracy=97%




Accuracy=100%

Ejemplo-2: Datos no separable linealmente


```
from sklearn.datasets import make_moons  
  
moons = make_moons(n_samples=300,  
noise=0.2, random_state=0)
```



Sin ruido



Resultados de clasificación



Resultados de clasificación



Clasificación Polynomial
Degree=5, coef0=1.0



Clasificación Polynomial
Degree=5, coef0=0.5

Accuracy = 98.7

Pipeline : Juntar mas de dos procesos en forma secuencial.

```
from sklearn.pipeline import Pipeline
```

Sin usar Pipeline

Estandarización

```
scaler = StandardScaler()  
SX_train = scaler.fit_transform(X_train)  
SX_test = scaler.transform(X_test)
```

Modelo de clasificación y aplicación

```
Classifier = SVC(kernel="rbf")  
Classifier.fit(SX_train, y_train)
```

Predicción

```
pred = Classifier.predict(SX_test)
```

Usar Pipeline



Estandarización + clasificación

```
kernel_svm = Pipeline(  
[ ('scaler', StandardScaler()),  
  ('svm', SVC(kernel="rbf"))  
)
```


Aplicación & predicción

```
kernel_svm.fit(X_train, y_train)  
pred = kernel_svm.predict(X_test)
```


Clasificar cáncer de mama usando dos características



Clasificación usando “mean_radius” y “mean_textura”



Tarea de SVM (Cáncer de mama)

- Realizar la clasificación usando más de dos características
- Probar diferentes kernels y diferentes grados en kernel de polinomio
- Realizar análisis de los resultados obtenidos.

Nota: Grid search con cross validation, se puede usar para obtener